

Biomedical Artificial Intelligence

**Perbandingan Klasifikasi Kuku Normal dan Kuku Terry
menggunakan CNN sederhana dan Transfer Learning
MobileNet**



Oleh :

Sayyidan Muhamad Ikhsan (20/460160/TK/50749)

**Departemen Teknik Elektro dan Informatika
Fakultas Teknik
Universitas Gadjah Mada
2023**

A. Latar Belakang

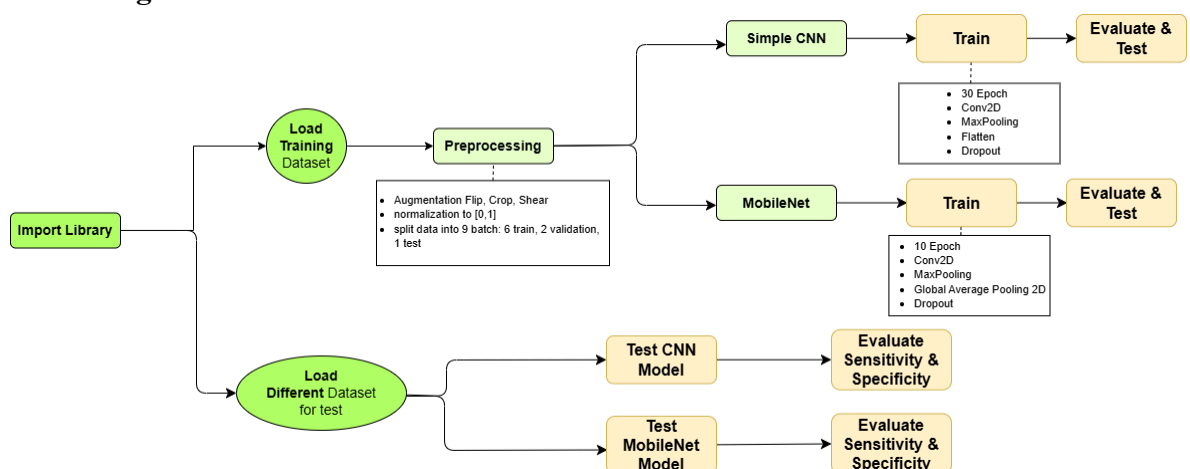
Terry's nails adalah suatu kondisi yang mempengaruhi kuku manusia, dimana terjadi serangkaian perubahan yang mencolok pada penampilan dan struktur kuku. Gejala utama dari *Terry's nails* mencakup kekeruhan hampir seluruh permukaan kuku, hilangnya lunula (bagian kecil berbentuk bulan sabit pada kuku), dan adanya pita sempit yang berwarna pink di tepi distal kuku. Meskipun perubahan ini dapat dianggap sebagai hasil dari penuaan alami, penting untuk memahami bahwa *Terry's nails* juga bisa menjadi indikator adanya kondisi medis yang mendasarinya, terutama penyakit-penyakit serius seperti sirosis, gagal ginjal kronis, dan gagal jantung kongestif.

Terry's nails adalah perubahan vaskularisasi pada tempat tidur kuku yang terjadi akibat pertumbuhan jaringan ikat di area tersebut. Hasil biopsi tempat tidur kuku sering mengungkapkan adanya telangiectasia di pita distal, yaitu perluasan pembuluh darah kecil yang dapat terlihat pada kulit atau selaput lendir.

Terry's nails tidak hanya mempengaruhi penampilan fisik kuku, tetapi juga dapat terkait dengan berbagai kondisi kesehatan lainnya. Beberapa di antaranya termasuk diabetes tipe 2, nefropati allograft kronis, hepatitis virus akut, vitiligo, dan lepra tuberkuloid.

Terry's nails memiliki implikasi klinis yang signifikan dengan penyakit serius, sehingga dengan mendeteksi perubahan pada kuku sejak dini, dokter dapat mengidentifikasi dan menganalisis lebih lanjut penyakit mendasar yang mungkin mempengaruhi kesehatan pasien. Teknologi machine learning memiliki peran penting dalam upaya ini, memungkinkan klasifikasi yang lebih cepat dan akurat antara *Terry's nails* dan kuku normal. Model yang dikembangkan menggunakan Convolutional Neural Network (CNN) sederhana dan penerapan transfer learning dengan MobileNet membuka peluang untuk meningkatkan efisiensi diagnosis, memberikan penanganan awal yang tepat, dan dengan demikian, meningkatkan prognosis serta perencanaan perawatan pasien secara lebih efektif. Kajian lebih lanjut dan pengembangan teknologi ini diharapkan dapat membawa manfaat dalam dunia medis.

B. Metodologi



Gambar 1. Pipeline

1. Dataset

Terdapat dua dataset yang digunakan, yaitu dataset yang digunakan untuk *training* model, dan dataset yang digunakan untuk menguji performa dari model yang telah di *training*. Kedua dataset ini diperoleh dari Kaggle dengan *keyword* pencarian “Nail”. Berikut beberapa gambar yang diperoleh dari kedua dataset tersebut.

Tabel 1. Sample Dataset

			
Terry's Nail	Terry's Nail	Normal Nail	Normal Nail

2. Preprocessing Data

Karena data yang didapatkan sangat minim, dilakukan augmentation, berupa *flip*, *crop*, dan *shear* agar data semakin beragam sehingga dapat meningkatkan performa model yang akan di-*training*. *Augmentation* adalah teknik untuk meningkatkan jumlah dan variasi data dengan melakukan transformasi seperti rotasi, pemotongan, atau penambahan noise. Teknik ini dapat mengurangi overfitting dan meningkatkan generalisasi model. Selain itu, data dinormalisasi yang bertujuan untuk menyamakan skala dan distribusi data sehingga mempercepat proses pembelajaran dan menghindari bias. Setelah itu, data dilakukan split per-*batch* dengan setiap *batch*-nya berisi 32 gambar. Total terdapat 9 *batch* dengan 6 *batch* untuk train, 2 *batch* untuk validasi, dan 1 *batch* untuk test.

3. Training

Selanjutnya adalah tahap training. Pada tahap ini, dilakukan training Menggunakan dua model berbeda, yaitu CNN (*Convolutional Neural Network*) dan MobileNet. MobileNet adalah model CNN yang dioptimalkan untuk perangkat seluler dan dapat bekerja dengan cukup baik pada data yang sedikit. Oleh karena itu, dipilih model MobileNet sebagai pembanding model CNN.

a. CNN

Model CNN dilatih dengan 30 Epoch dan menggunakan beberapa layer yang terdiri dari lapisan konvolusi, Max Pooling, Flatten, Dense, dan Drop out.

Lapisan konvolusi dengan fungsi aktivasi relu yang berfungsi untuk melakukan ekstraksi fitur dari gambar input dengan

menggunakan filter yang memiliki bobot acak. Fungsi aktivasi relu mengubah nilai negatif menjadi nol dan mempertahankan nilai positif, sehingga dapat meningkatkan non-linearitas model.

Lapisan Max Pooling berfungsi untuk melakukan reduksi dimensi dari output lapisan konvolusi dengan cara memilih nilai maksimum dari setiap wilayah tertentu. Hal ini dapat mengurangi jumlah parameter, mencegah overfitting, dan meningkatkan invarian terhadap translasi.

Lapisan Flatten berfungsi untuk mengubah output lapisan pooling menjadi vektor satu dimensi yang dapat digunakan sebagai input untuk lapisan padat.

Lapisan Dense berfungsi untuk melakukan operasi perkalian matriks antara vektor input dengan matriks bobot yang memiliki ukuran sesuai dengan jumlah unit pada lapisan tersebut. Lapisan ini dapat merepresentasikan hubungan antara fitur-fitur input dengan kelas-kelas output.


Lapisan Dropout berfungsi untuk melakukan penghapusan secara acak dari sebagian unit pada output lapisan padat dengan probabilitas tertentu. Tujuan dari lapisan ini adalah untuk mencegah overfitting dan meningkatkan generalisasi model.

Layer (type)	Output Shape	Param #
conv2d_65 (Conv2D)	(None, 254, 254, 32)	896
max_pooling2d_65 (MaxPooling2D)	(None, 127, 127, 32)	0
conv2d_66 (Conv2D)	(None, 125, 125, 16)	4624
max_pooling2d_66 (MaxPooling2D)	(None, 62, 62, 16)	0
conv2d_67 (Conv2D)	(None, 60, 60, 8)	1160
max_pooling2d_67 (MaxPooling2D)	(None, 30, 30, 8)	0
flatten_25 (Flatten)	(None, 7200)	0
dense_52 (Dense)	(None, 256)	1843456
dropout_27 (Dropout)	(None, 256)	0
dense_53 (Dense)	(None, 1)	257
Total params: 1850393 (7.06 MB)		
Trainable params: 1850393 (7.06 MB)		
Non-trainable params: 0 (0.00 Byte)		

Gambar 2. Model summary CNN

Model CNN ini kemudian menggunakan optimizer *adam*. Optimizer Adam menggabungkan dua teknik optimisasi lainnya, yaitu momentum dan RMSprop. Momentum adalah teknik untuk

mempercepat konvergensi dengan menggunakan rata-rata bergerak dari gradien, sedangkan RMSprop adalah teknik untuk menyesuaikan laju pembelajaran dengan menggunakan rata-rata bergerak dari kuadrat gradien. Berikut merupakan grafik *loss* dan *accuracy* dari tahap training.



Gambar 3. *Loss* dan *accuracy* CNN

Pada epoch 30, didapatkan *loss* sebesar 0,053, akurasi sebesar 0.974, validasi *loss* sebesar 0.0315, dan validasi akurasi sebesar 1. Selanjutnya dilakukan pengujian model pada data test dan menghasilkan presisi 100%, recall 100%, dan akurasi 100%. Meskipun hasil parameter ini bagus, terdapat kemungkinan terjadi *overfitting* yang disebabkan karena data yang olah sangat lah kecil dan kurang beragam


b. MobileNet

MobileNet digunakan sebagai model pembanding dari CNN sederhana sebelumnya. MobileNet dipilih karena memiliki model yang ringan dan efisien untuk mengolah data kecil. MobileNet yang digunakan memiliki beberapa layer tambahan yang sama mirip seperti model CNN sebelumnya, yaitu layer konvolusional, layer Max Pooling, layer Dropout, dan layer Dense. Selain itu, terdapat layer Global Average Pooling yang berfungsi untuk mengurangi jumlah parameter yang diperlukan dengan mengambil nilai rata-rata sehingga dapat mengurangi kemungkinan terjadinya *overfitting*. Sama seperti model CNN sebelumnya, pada MobileNet ini juga menggunakan optimizer *adam*. Kemudian, dataset di-*training* menggunakan 10 Epoch.

Layer (type)	Output Shape	Param #
mobilenet_1.00_224 (Functional)	(None, 7, 7, 1024)	3228864
conv2d_1 (Conv2D)	(None, 5, 5, 64)	589888
max_pooling2d_1 (MaxPooling2D)	(None, 2, 2, 64)	0
global_average_pooling2d (GlobalAveragePooling2D)	(None, 64)	0
dropout_1 (Dropout)	(None, 64)	0
classification (Dense)	(None, 1)	65
Total params: 3818817 (14.57 MB)		
Trainable params: 589953 (2.25 MB)		
Non-trainable params: 3228864 (12.32 MB)		

Gambar 4. Model summary MobileNet

Berikut merupakan grafik *loss* dan *accuracy* hasil training dengan 10 epoch.



Gambar 5. *Loss* dan *accuracy* MobileNet

Didapatkan *loss* sebesar 0.0523, *accuracy* sebesar 0.9948, *validation loss* sebesar 0.0109, dan *validation* 1. Kemudian dilakukan pengujian pada data test dan menghasilkan presisi 100%, recall 100%, dan akurasi 100%. Sama seperti model CNN sebelumnya, terdapat kemungkinan overfitting akibat data yang diolah kecil.


4. Evaluasi *sensitivity* dan *specificity*

Karena terdapat kemungkinan hasil yang diperoleh sebelumnya terjadi *overfitting*, dilakukan evaluasi kembali model yang telah di-*training* menggunakan dataset yang berbeda untuk mencari sensitivitas dan spesifisitas model dalam memprediksi data baru. Sensitivitas adalah kemampuan model untuk memprediksi benar kasus positif dari suatu kondisi, sedangkan spesifisitas adalah kemampuan model dalam mengecualikan benar kasus negatif dari suatu kondisi. Sebelum mencari kedua metrik ini, dicari terlebih dahulu nilai True Positives (TP), True Negatives (TN), False Positives (FP), dan False Negative (FN)

C. Hasil

1. CNN

Gambar X menunjukkan *confusion matrix* hasil prediksi menggunakan model CNN yang sebelumnya dilatih.



Gambar X. *Confusion Matrix* CNN Model


Berdasarkan hasil prediksi, didapatkan *True Positives* (TP) sebesar 22, *True Negatives* (TN) sebesar 20, *False Positive* (FP) sebesar 14, dan *False Negatif* (FN) sebesar 14.

Hasil klasifikasi menunjukkan bahwa sensitivitas (*True Positive Rate*) sebesar 0,61, mengindikasikan bahwa model berhasil mengidentifikasi sekitar 61% dari seluruh kuku yang sebenarnya adalah *Terry's nail*. Sensitivitas mencerminkan kemampuan model untuk mengenali kasus positif dengan akurasi relatif tinggi, tetapi ada sekitar 39% kasus *Terry's nail* yang tidak teridentifikasi. Di sisi lain, spesifisitas (*True Negative Rate*) sebesar 0,59 menunjukkan bahwa model dapat mengidentifikasi *normal nails* sekitar 59% dari seluruh kasus yang sebenarnya normal. Namun, sekitar 41% kasus normal nails salah diidentifikasi sebagai *Terry's nail*. Oleh karena itu, model ini memiliki tingkat kesalahan yang signifikan, dan peningkatan performa perlu diupayakan untuk meminimalkan kesalahan diagnosa.

Secara keseluruhan, model ini mendapatkan akurasi sebesar 63% dalam mengklasifikasi *Terry's nails* dan *normal nails*.

2. MobileNet

Gambar X menunjukkan *confusion matrix* hasil prediksi menggunakan model MobileNet



Gambar X *Confusion Matrix* Model MobileNet

Berdasarkan hasil prediksi, didapatkan *True Positives* (TP) sebesar 30, *True Negatives* (TN) sebesar 24, *False Positive* (FP) sebesar 10, dan *False Negatif* (FN) sebesar 6.

Hasil klasifikasi menunjukkan sensitivitas (*True Positive Rate*) sebesar 0,83, menandakan bahwa model berhasil mengidentifikasi sekitar 83% dari seluruh kuku yang sebenarnya adalah *Terry's nail*. Sensitivitas yang tinggi menggambarkan kemampuan model untuk mengenali kasus positif dengan akurasi relatif tinggi, tetapi masih terdapat sekitar 17% kasus *Terry's nail* yang diidentifikasi sebagai *normal nails*.

Di sisi lain, spesifisitas (*True Negative Rate*) sebesar 0,71 menunjukkan bahwa model dapat mengidentifikasi normal nails sekitar 71% dari seluruh kasus yang sebenarnya normal. Namun, sekitar 29% kasus normal nails salah diidentifikasi sebagai *Terry's nail*. Meskipun spesifisitas cukup tinggi, ada potensi untuk meminimalkan angka false positive agar diagnosa lebih akurat, terutama untuk memastikan bahwa pasien dengan normal nails tidak salah dianggap memiliki *Terry's nail*.

Secara keseluruhan, model MobileNet ini mendapatkan akurasi sebesar 77% dalam mengklasifikasi *Terry's nails* dan *normal nails*

D. Kesimpulan

Dalam penelitian ini, dua model arsitektur *neural network*, yaitu *Convolutional Neural Network* (CNN) dan MobileNet, dievaluasi untuk tugas klasifikasi kuku sebagai *Terry's nail* atau normal. Evaluasi dilakukan menggunakan *confusion matrix*, yang memberikan gambaran visual tentang performa kedua model.

Model CNN menunjukkan tingkat sensitivitas sekitar 61% dan spesifisitas sekitar 59%. Sementara itu, model MobileNet mencapai tingkat sensitivitas sekitar 83% dan spesifisitas sekitar 71%. Hal ini mengindikasikan bahwa MobileNet memiliki performa lebih baik dalam mengidentifikasi kasus *Terry's nail* dengan tingkat akurasi yang lebih tinggi dibandingkan CNN.

Menariknya, MobileNet mencapai tingkat akurasi yang cukup tinggi, yaitu sekitar 77%, dengan hanya membutuhkan 10 epoch untuk pelatihan. Di sisi lain, CNN memerlukan 30 epoch untuk mencapai tingkat akurasi yang lebih rendah, yaitu sekitar 63%. Hal ini menunjukkan efisiensi dan efektivitas pelatihan yang lebih baik pada model MobileNet.

Hasil ini menandakan bahwa MobileNet merupakan pilihan yang lebih efisien dalam konteks klasifikasi kuku ini, mengingat mampu mencapai tingkat akurasi yang lebih tinggi dengan waktu pelatihan yang lebih singkat. Penelitian lebih lanjut dapat difokuskan pada optimalisasi performa model MobileNet untuk meminimalkan false positives dan false negatives serta meningkatkan akurasi secara keseluruhan.